第二次作业

KaiWenZhai

2026.4.7

摘要

本文针对三维特征空间下的多分类任务，系统研究了决策树、AdaBoost 集成学习以及支持向量机（SVM）三种经典机器学习算法的原理与实现。首先阐述了决策树的划分准则与生成逻辑，其次基于 SAMME 算法实现了 AdaBoost 与决策树的多分类扩展，最后推导了 SVM 从硬间隔、软间隔到核函数的完整理论体系。通过对比实验验证不同算法的分类性能，分析了模型参数与核函数对实验结果的影响，为多分类任务的算法选择与参数优化提供了实践依据。

关键词：决策树；AdaBoost；支持向量机；多分类；核函数

1 引言

在机器学习与模式识别领域，分类算法是解决实际问题的核心工具。三维特征数据的多分类任务广泛存在于图像识别、故障诊断、数据分析等应用场景中，要求模型具备良好的非线性拟合能力与泛化性能。

决策树作为直观易懂的非线性分类模型，具备可解释性强、训练速度快的优势，但容易出现过拟合现象；AdaBoost 集成算法通过组合多个弱分类器构建强分类器，能够有效提升模型精度与鲁棒性；支持向量机基于间隔最大化理论，借助核函数技巧可高效处理非线性可分问题，是小样本场景下的优选算法。

本文围绕上述三种算法展开理论推导与实验验证，对比分析其在三维多分类数据集上的表现，总结各算法的适用场景与优缺点，为相关机器学习任务提供参考。

2 研究方法

2.1 决策树

2.1.1 决策树

决策树是一种监督学习中的分类与回归方法，其本质是通过对特征空间进行递归划分，构建一组用于决策的树形结构。树中每个内部节点表示一个特征测试，每个分支表示测试结果，每个叶节点表示最终输出类别。在决策书中，越靠近根节点的分叉，对数据的分类能力越强。

给定训练集 $D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_m, y_m)\}$，其中 $x_i \in \mathbb{R}^d$ 为 d 维特征向量，$y_i \in \{c_1, c_2, \ldots, c_k\}$ 为类别标签。决策树的目标便是学习一组分层划分规则，使得对任意输入样本，能够快速映射到对应类别。

2.1.2 划分准则

划分的目的就是让集合更纯，故需要定义一个集合混乱的程度指标。

信息熵用于衡量集合的纯度，定义为：

$$H(D) = -\sum_{i=1}^{k} p_i \log_2 p_i \tag{1}$$

其中 p_i 为集合 D 中第 i 类样本所占比例。熵越小，样本集纯度越高；熵越大，样本集混乱程度越高。

也可以采用基尼系数来定义：

$$Gini(D) = 1 - \sum_{i=1}^{k} p_i^2 \tag{2}$$

基尼指数越小，数据集纯度越高。

在计算某一划分的能力时，需要通过对分类后不同类别的占比对计算出来分类后每个类别的基尼系数进行加权求和即：

$$Total(D) = \sum_{i=1}^{k} Gini(D_i) p_i \tag{3}$$

2.1.3 决策树预测

对于待预测样本 x，从决策树根节点开始，根据特征取值依次向下遍历，直至到达叶节点，输出对应类别。

Algorithm 1 决策树生成算法

Require: 训练集 D，特征集 A

Ensure: 生成决策树 T

```
若 D 中所有样本属于同一类别，则返回单节点树
若 A = ∅ 或样本在特征上取值相同，则将叶节点标记为多数类
根据划分准则（信息增益/基尼指数）从 A 中选择最优划分特征 a_*
根据 a_* 的取值将 D 划分为若干子集 D_v
对每个子集递归调用生成算法，构建子树
return 决策树 T
```

2.2 AdaBoost+ 决策树（K 分类扩展）

2.2.1 基本原理

AdaBoost 算法可通过扩展实现 K 分类任务，其核心思想仍为迭代训练多个决策树弱分类器，动态调整样本权重与分类器权重，将多个弱分类器集成为适用于多分类场景的强分类器。给定三维训练集 $X \in \mathbb{R}^{N\times 3}$，标签集 $y \in \{0, 1, \ldots, K-1\}$，算法通过逐步聚焦困难样本，优化多分类决策边界，适用于多类别三维数据的非线性分类需求。

2.2.2 核心公式

样本权重初始化 初始时所有样本权重相等，保证首次训练时各类样本被平等对待：

$$w_i = \frac{1}{N}, \quad i = 1, 2, \ldots, N \tag{4}$$

其中 N 为样本总数，w_i 为第 i 个样本的初始权重。

弱分类器错误率 基于当前权重分布，计算多分类决策树弱分类器的加权错误率：

$$\epsilon_m = \sum_{i=1}^{N} w_i \cdot \mathbb{I}(h_m(x_i) \neq y_i) \tag{5}$$

其中 $h_m(x_i)$ 为第 m 个弱分类器输出的类别标签，$y_i \in \{0, 1, \ldots, K-1\}$ 为真实标签，$\mathbb{I}(\cdot)$ 为指示函数，分类错误时取 1，正确时取 0。

弱分类器权重 多分类 AdaBoost（SAMME）采用如下公式计算弱分类器权重，错误率越低则权重越大：

$$\alpha_m = \frac{1}{2} \ln\left(\frac{1-\epsilon_m}{\epsilon_m}\right) + \ln(K-1) \tag{6}$$

样本权重更新 分类错误的样本权重提升，正确的样本权重保持或降低，使后续分类器专注困难样本：

$$w_{i,m+1} = \frac{w_{i,m} \cdot \exp\left(\alpha_m \cdot \mathbb{I}(h_m(x_i) \neq y_i)\right)}{Z_m} \tag{7}$$

其中 Z_m 为归一化因子，确保权重之和为 1。

强分类器输出 最终强分类器通过加权投票输出概率最大的类别，实现 K 分类：

$$H(x) = \arg\max_{k\in\{0,\dots,K-1\}} \sum_{m=1}^{M} \alpha_m \cdot \mathbb{I}(h_m(x) = k) \tag{8}$$

其中 M 为弱分类器总数，$\arg\max$ 选择加权得分最高的类别作为最终输出。

2.3 SVM 支持向量机

2.3.1 基本思想

支持向量机是一种经典的有监督机器学习算法，核心目标是在特征空间中寻找一个最优分类超平面，使得不同类别样本之间的间隔最大化，从而获得最强的泛化能力。

给定二分类训练数据集：

$$D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \dots, (\boldsymbol{x}_m, y_m)\}, \quad y_i \in \{+1, -1\}$$

其中：$\boldsymbol{x}_i \in \mathbb{R}^d$ 为 d 维特征向量，y_i 为样本标签（$+1$ 代表正类，-1 代表负类）。

分类超平面的一般形式为：

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b = 0$$

$\boldsymbol{w}$ 为超平面法向量，b 为偏置项。

样本到超平面的几何间隔定义为：

$$\gamma_i = \frac{y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b)}{\|\boldsymbol{w}\|}$$

SVM 的核心是最大化最小几何间隔 $\gamma = \min\limits_{i=1,\dots,m} \gamma_i$。

2.3.2 硬间隔 SVM 数学建模

为简化计算，令函数间隔 $y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geq 1$（归一化约束），此时最小几何间隔为 $\frac{1}{\|\boldsymbol{w}\|}$。

最大化间隔等价于最小化 $\|\boldsymbol{w}\|$，因此硬间隔 SVM 优化目标为：

$$\begin{cases} \min\limits_{\boldsymbol{w},b} \quad \dfrac{1}{2}\|\boldsymbol{w}\|^2 \\ \text{s.t.} \quad y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{cases}$$

2.3.3 拉格朗日对偶推导

引入拉格朗日乘子 $\alpha_i \geq 0$，构造拉格朗日函数:

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m} \alpha_i \left[y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) - 1\right]$$

根据 KKT 条件，原始问题等价于对偶问题:

$$max_{\boldsymbol{\alpha}} min_{\boldsymbol{w},b} L(\boldsymbol{w}, b, \boldsymbol{\alpha})$$

第一步：对 $\boldsymbol{w}, b$ 求偏导并令其为 0

$$\frac{\partial L}{\partial \boldsymbol{w}} = \boldsymbol{w} - \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i = 0 \implies \boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \implies \sum_{i=1}^{m} \alpha_i y_i = 0$$

第二步：代入拉格朗日函数化简对偶问题将 $\boldsymbol{w}$ 和约束代入 L，得到:

$$max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$$

约束条件:

$$\begin{cases} \alpha_i \geq 0, \quad i = 1, \ldots, m \\ \sum_{i=1}^{m} \alpha_i y_i = 0 \end{cases}$$

第三步：求解分类模型解出最优乘子 $\boldsymbol{\alpha}^*$ 后，计算:

$$\boldsymbol{w}^* = \sum_{i=1}^{m} \alpha_i^* y_i \boldsymbol{x}_i$$

选择满足 $\alpha_i^* > 0$ 的支持向量 $(\boldsymbol{x}_s, y_s)$，计算偏置:

$$b^* = y_s - \boldsymbol{w}^{*\mathrm{T}} \boldsymbol{x}_s$$

最终分类决策函数:

$$f(\boldsymbol{x}) = \operatorname{sign}\left(\sum_{i=1}^{m} \alpha_i^* y_i \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x} + b^*\right)$$

2.3.4 核函数：处理非线性可分问题

对于线性不可分数据，通过核函数将低维特征映射到高维空间，使其线性可分。

核函数定义:

$$K(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^{\mathrm{T}} \phi(\boldsymbol{x}_j)$$

无需显式计算映射 ϕ，直接计算内积。

常用核函数:

1. 线性核：$K(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$
2. 高斯核（RBF）：$K(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2\sigma^2}\right)$
3. 多项式核：$K(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j + c)^d$

引入核函数后，对偶目标改写为：

$$max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j K(\boldsymbol{x}_i, \boldsymbol{x}_j)$$

2.3.5 软间隔 SVM：处理噪声与异常值

现实数据存在噪声，允许少量样本违反间隔约束，引入松弛变量 $\xi_i \geq 0$ 和惩罚参数 $C > 0$。

优化目标：

$$\begin{cases} \min\limits_{\boldsymbol{w}, b, \boldsymbol{\xi}} \quad \dfrac{1}{2}\|\boldsymbol{w}\|^2 + C \displaystyle\sum_{i=1}^{m} \xi_i \\ \text{s.t.} \quad y_i(\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \end{cases}$$

C 越大，对误分类惩罚越重；C 越小，泛化能力越强。

其对偶问题与硬间隔形式一致，仅约束变为 $0 \leq \alpha_i \leq C$。

2.3.6 总体理解

本意是想构建一个分割的超平面，但在求解极值过程中，发现不需要知道 w 具体是多少，可以通过求解 $alpha_i$ 得到。而采用核函数可以假想已经把训练数据上升到一个超高维上，但是不用具体计算其数值是多少，因为采用不同核就是采用不同的内积计算方式，使得非线性区分效果更好。

3 实验结果

3.1 决策树

在实验中发现，设置最大深度为 4 时，分类预测效果最好。深度过浅会导致模型欠拟合，无法充分学习数据特征；深度过深则会引发过拟合，降低模型在测试集上的泛化能力。

3.2 Adaboost+ 决策树

在实验中，取决策树最大深度为 4，集成 10 棵决策树进行加权投票。实验结果表明，AdaBoost 集成模型有效弥补了单棵决策树的精度不足，通过权重迭代优化，显著提升了对困难样本的分类能力，分类边界更加平滑。

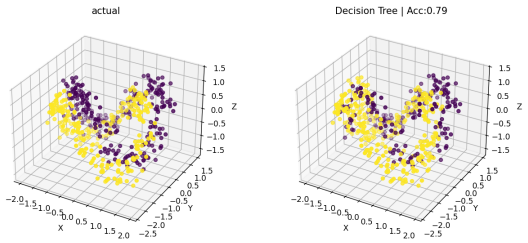

图 1: 决策树分类结果可视化

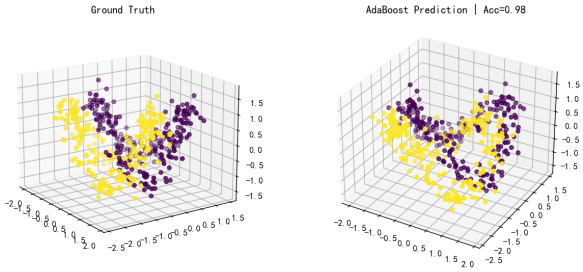

图 2: AdaBoost 决策树分类结果可视化

3.3 SVM 支持向量机

本实验对比了线性核、多项式核与高斯核（RBF）三种核函数的分类效果。可见线性核效果最差，仅能实现线性分割；多项式核效果适中；高斯核凭借高维映射能力，能够拟合复杂的非线性决策边界，在三维多分类任务中表现最佳。

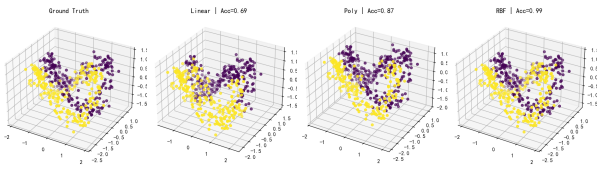

图 3: 不同核函数 SVM 分类结果对比

4 结论

本文通过理论推导与对比实验，系统研究了决策树、AdaBoost 集成学习与 SVM 三种算法在三维多分类任务中的应用。实验结果表明：

1. 单决策树模型可解释性强，但泛化能力有限，合理设置最大深度可有效缓解过拟合问题；

2. AdaBoost 集成决策树通过组合弱分类器，大幅提升了分类精度，是兼顾效率与性能的优选方案；

3. SVM 算法中，高斯核函数在非线性分类任务中表现最优，能够高效处理三维特征的复杂分布。

综合来看，在小样本、非线性的三维多分类场景下，高斯核 SVM 与 AdaBoost 决策树均能取得优异效果；若追求模型可解释性，可选择参数优化后的决策树。未来可进一步结合特征工程与超参数调优方法，提升模型在实际场景中的应用性能。