基于多变量 LSTM 网络的 PM2.5 浓度时序预测实验报告

kaiwenZhai

23373360

摘要

空气中细颗粒物浓度变化受气象条件、环境因素共同制约，具备典型的时间序列变化特征。传统时序分析方法难以刻画多气象因子与污染物浓度之间的非线性关联，而长短期记忆神经网络（LSTM）凭借独特的内部记忆结构，能够有效挖掘长时间跨度下的时序变化规律。本次实验以城市空气质量小时级监测数据为研究对象，综合温度、气压、风速、湿度、雨雪记录等多项环境指标，搭建多变量输入的 LSTM 预测模型，以历史二十四小时连续观测数据为基础，实现未来一小时 PM2.5 浓度的定量预测。实验完成数据清洗、特征编码、序列构造、模型训练与结果检验整套流程，通过误差指标与拟合曲线综合分析模型效果，验证 LSTM 网络在短期空气质量预测场景中的实际应用价值。

关键词： 时序预测；LSTM；多变量融合；PM2.5；环境监测

1 实验背景与研究意义

随着城市环境监测体系不断完善，长时间连续的空气质量时序数据得以积累，利用历史观测数据实现污染物浓度短周期预测，对环境预警与健康防护具备实际参考意义。PM2.5 作为核心空气污染物，其浓度并非随机波动，不仅存在以天为单位的周期性变化，还会实时受到气温、气压、风向、降水等气象条件的直接影响。

在传统建模方式中，差分回归、灰色预测等方法仅适用于简单单一变量的平稳序列分析，面对多因子耦合、非线性强、波动幅度大的污染数据，拟合能力明显不足。循环神经网络及其改进模型专门针对序列型数据设计，其中 LSTM 网络解决了基础循环结构在长距离信息传递过程中的梯度衰减问题，可以稳定保存前期关键时序信息，更加适配长时间、多变量的环境监测数据建模需求。因此本次实验选用多变量 LSTM 结构，开展小时尺度下的 PM2.5 浓度预测研究。

2 LSTM 网络结构与工作原理

2.1 基础问题与结构改进思路

基础循环神经网络在逐时刻迭代计算时，早期时刻的特征信息会随着序列长度增加不断衰减，当输入序列跨度达到二十四小时甚至更长时，模型难以关联历史状态与当前预测目标，出现记忆失效问题。LSTM 作为改进型循环结构，通过引入门控控制与独立细胞记忆单元，人为构建信息筛选与长期存储机制，从结构上缓解长序列建模困难的问题。

2.2 内部单元组成与信息流转逻辑

LSTM 整体沿用时序循环迭代的计算框架，每一个时刻的网络单元主要包含隐藏状态与细胞记忆两个信息载体：隐藏状态负责输出当前时刻的短期特征，细胞记忆则作为长期信息的传递载体，贯穿整个时间序列，保证关键历史特征能够跨时刻保留。

为实现信息的选择性留存与丢弃，单元内部设置三类控制门：**遗忘门**依据当前输入与上一时刻状态，判断过往记忆中哪些无效信息需要舍弃，过滤冗余历史数据；**输入门**负责筛选当前时刻的有效特征，将气象、污染等新增关键信息整合录入长期记忆；**输出门**结合记忆单元状态与实时输入，筛选适宜的特征信息输出至隐藏层，为最终预测提供有效表征。

整套门控机制协同工作，让网络自主学习不同时段、不同环境变量对污染浓度的影响权重，既保留短时间内的实时变化特征，又能记忆多天内的周期性变化规律，非常适合本次实验的小时级连续预测任务。

2.3 核心计算公式

LSTM 通过遗忘门、输入门、细胞状态与输出门四部分协同完成时序信息更新，各模块计算公式与物理含义逐一展开说明。

1. 遗忘门

$$f_t = \sigma\big(W_f \boldsymbol{x}_t + U_f \boldsymbol{h}_{t-1} + \boldsymbol{b}_f\big)$$

遗忘门结合当前时刻输入特征 $\boldsymbol{x}_t$ 与上一时刻隐藏状态 $\boldsymbol{h}_{t-1}$ 做线性映射，经由 Sigmoid 激活函数压缩至 $[0,1]$ 区间。输出 f_t 作为记忆筛选权重，控制上一阶段长期记忆的保留比例，完成冗余历史信息的过滤操作。

2. 输入门

$$i_t = \sigma\big(W_i \boldsymbol{x}_t + U_i \boldsymbol{h}_{t-1} + \boldsymbol{b}_i\big)$$

输入门与遗忘门结构形式一致，同样利用 Sigmoid 函数生成权重系数 i_t，专门用于判断当前时刻新增特征的有效程度，筛选需要存入长期记忆的实时信息。

3. 候选记忆单元

$$\tilde{\boldsymbol{c}}_t = \tanh\left(W_c \boldsymbol{x}_t + U_c \boldsymbol{h}_{t-1} + \boldsymbol{b}_c\right)$$

该部分利用 tanh 激活函数生成取值在 $[-1, 1]$ 的临时候选记忆 $\tilde{\boldsymbol{c}}_t$，对当前时刻环境与污染特征做非线性变换，为记忆更新提供备选内容。

4. 细胞状态更新

$$\boldsymbol{c}_t = f_t \odot \boldsymbol{c}_{t-1} + i_t \odot \tilde{\boldsymbol{c}}_t$$

细胞状态 $\boldsymbol{c}_t$ 是 LSTM 的长期记忆载体。通过逐元素相乘运算 $\odot$，一方面由遗忘门淘汰无效旧记忆，另一方面由输入门筛选融合新候选记忆，实现时序信息的迭代更新。

5. 输出门

$$o_t = \sigma\left(W_o \boldsymbol{x}_t + U_o \boldsymbol{h}_{t-1} + \boldsymbol{b}_o\right)$$

输出门依旧采用 Sigmoid 激活，生成控制记忆输出的权重 o_t，依据当前输入与历史状态，决定长期记忆中需要对外输出的有效内容。

6. 当前隐藏状态

$$\boldsymbol{h}_t = o_t \odot \tanh(\boldsymbol{c}_t)$$

将更新后的细胞状态压缩至 $[-1, 1]$，结合输出门权重做筛选，得到当前时刻最终隐藏输出 $\boldsymbol{h}_t$，作为特征表征送入全连接层完成预测。

式中：W U 为对应权重矩阵，$\boldsymbol{b}$ 为偏置向量；σ 代表 Sigmoid 激活函数，$\odot$ 表示矩阵逐元素乘法运算。

3 实验数据集与预处理方案

3.1 数据集基本概况

实验所用数据来源于 Kaggle 公开空气质量监测数据集，整合两份同结构监测文件，包含连续多年小时级采样记录。数据除核心观测指标 PM2.5 污染浓度外，同步记录露点温度、环境温度、地表气压、合成风速、积雪时长、降雨时长及风向等辅助变量，依靠多维度环境数据支撑多变量时序建模。

3.2 数据预处理详细流程

原始监测数据存在缺失值、类别特征混杂、量纲不统一等问题，需要经过系统化处理后才可输入神经网络训练：

1. 数据整合与规整：读取两份原始数据文件，完成字段名统一与格式标准化，按照时间字段升序排列，保证时序前后顺序严格正确；

2. 缺失值处理：以 PM2.5 目标变量为核心，删除关键指标缺失的无效样本，其余环境特征的缺失位置采用全局均值填充，减少数据损耗；

3. 类别特征编码：风向为离散类别量，无法直接参与数值计算，采用独热编码方式完成数字化转换，融入整体特征体系；

4. 数值归一化：各环境指标量纲、数值范围差异较大，利用最大-最小值归一化将全部特征映射至 $[0,1]$ 区间，避免量级差异干扰模型收敛；

5. 时序样本构造：设置 24 小时为固定观测窗口，以连续 24 组多变量观测数据作为单条输入样本，以下一时刻 PM2.5 浓度作为预测标签，完成静态表格数据到时序序列样本的转换。

4 实验模型搭建与训练设置

4.1 网络整体配置

本次实验严格按照时序回归任务需求搭建轻量化 LSTM 网络，网络结构由输入层、LSTM 层、Dropout 层与全连接输出层依次组成，各层参数与功能严格匹配多变量小时级预测需求，具体结构如下：

（1）输入层输入维度固定为 $(24,17)$。其中 24 代表时间窗口长度，即使用过去 24 小时连续观测数据作为模型输入；17 代表特征总数，包含 PM2.5 浓度、温度、露点、气压、风速、降雨、降雪等气象特征，hour_sin、hour_cos、month_sin、month_cos 周期特征，以及风向独热编码向量。输入层直接将标准化后的时序数据传入 LSTM 单元进行特征提取。

（2）LSTM 层采用单层 LSTM 结构，隐藏单元数量设置为 64，激活函数使用 tanh。该层为网络核心结构，用于捕捉时间序列中的短期波动与长期依赖关系，自动学习 PM2.5 浓度随时间、气象条件变化的趋势规律。LSTM 层最终输出形状为 (64)，即将每条 24 小时长度的时序样本转化为 64 维的隐藏特征向量。

（3）Dropout 层在 LSTM 层后添加 Dropout 正则化层，丢弃率设置为 0.2。在模型训练过程中随机丢弃 20% 的神经元连接，降低网络对训练数据的过度依赖，有效抑制过拟合，提升模型在未知数据上的泛化能力。

（4）全连接输出层采用单层全连接层，输出维度为 1，用于预测未来一小时的 PM2.5 浓度。该层将 LSTM 输出的高维隐藏特征映射为单值预测结果，完成从时序特征到浓度预测的转换。

4.2 损失函数、评价指标与训练设置

本次模型采用回归任务常用配置，兼顾训练稳定性与评价直观性：

- 损失函数：使用均方误差（mean_squared_error, MSE），对预测误差进行平方后求平均，强化对大误差样本的惩罚力度；
- 评价指标：使用平均绝对误差(mean_absolute_error, MAE)与均方根误差(RMSE)，直观反映预测值与真实值的平均偏差程度；
- 尺度说明：最终报告的 MAE 与 RMSE 均为归一化尺度下的计算结果，若需转换为原始浓度尺度，需对预测值与真实值执行反归一化后重新计算。

数据集划分严格遵循时序规则：按照时间先后顺序，前 80% 样本作为训练集，后 20% 作为测试集，不打乱时序顺序。模型使用 Adam 优化器，训练轮次 30 轮，批次大小 32，在保证收敛速度的同时提升训练稳定性。

5 实验结果与分析

5.1 量化误差指标

模型训练完成后，分别在训练集与测试集上开展预测检验，采用均方根误差 RMSE、平均绝对误差 MAE 两项常用回归指标量化误差：

- 训练集 RMSE：26.88
- 测试集 RMSE：24.92
- 训练集 MAE：14.77
- 测试集 MAE：13.85

从指标结果可以看出，模型在训练与测试数据上误差差距较小，整体泛化能力良好，未出现严重过拟合或欠拟合现象。

5.2 拟合效果综合分析

结合损失下降曲线与测试集预测对比曲线可以发现：模型损失在迭代前期快速下降，后期逐步趋于平稳收敛，说明网络参数完成有效学习，特征利用充分。

在实际浓度拟合方面，LSTM 模型可以精准跟随 PM2.5 浓度的整体变化趋势，对于日常平稳区间的常规浓度波动拟合效果良好；针对短时突变的污染峰值，预测结果存在小幅滞后与偏差，这是由于突发污染受人为排放、局部气象突变等额外因素影响，仅依靠常规时序气象数据难以完全精准复刻。整体来看，模型输出曲线与真实监测曲线走势高度吻合，能够满足短期小时级污染浓度预测的基本使用需求。

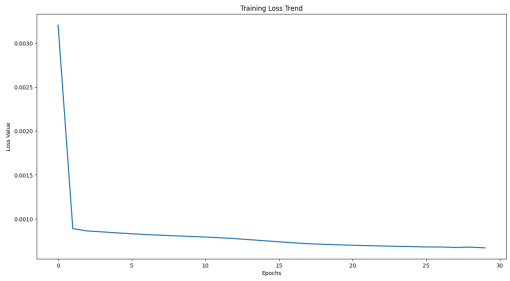

图 1: 损失下降曲线

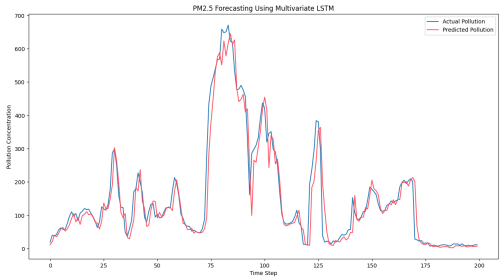

图 2: 实际拟合曲线效果

6 实验结论

本次实验围绕多变量时序回归任务，完成从原始环境监测数据处理、时序样本构建、LSTM 模型搭建到预测效果评估的完整实验流程。通过引入多类气象辅助变量，结合 LSTM 长时序记忆优势，有效挖掘了二十四小时周期内环境因子与 PM2.5 浓度的动态关联。

实验结果表明：相较于单一变量的趋势拟合，多变量融合输入能够显著提升预测合理性；LSTM 凭借门控记忆结构，在长时间序列环境数据建模中具备明显优势，可以稳定捕捉周期性变化与非线性耦合规律。后续可通过调整时序窗口长度、优化网络层数与神经元数量、引入更多环境影响因子等方式，进一步优化峰值预测精度，为区域空气质量短周期预报提供更加可靠的模型支撑。