

Attention Is All You Need 的结构复现与关键模块消融实验研究

姓名：翟凯文 学号：23373360

2026 年 5 月 19 日

摘要

本文围绕 Vaswani 等人在 *Attention Is All You Need* 中提出的 Transformer 架构进行轻量级复现与消融实验。考虑到完整复现 WMT 2014 机器翻译实验需要较高算力，本文采用 synthetic reverse sequence-to-sequence 任务作为可控验证平台：输入为随机整数序列，输出为其反转序列。该任务语义简单，但对 token 顺序和输入输出位置对应关系高度敏感，因此适合检验 Transformer 中位置编码、Q/K/V 分工、残差连接与 LayerNorm 等结构是否真正必要。

本文在复现 scaled dot-product attention、multi-head attention、position-wise feed-forward network、sinusoidal positional encoding、residual connection 与 layer normalization 的基础上，重点完成两组消融实验：第一，比较无位置编码、简单绝对位置编码、可学习位置编码和正弦位置编码；第二，比较标准 Add & Norm、去掉残差连接、去掉 LayerNorm 和同时去掉二者。与只报告 loss 或 token accuracy 的写法不同，本文进一步整理了完整序列准确率、最佳轮次、loss 下降幅度、梯度范数均值和最大值等指标，并结合终端训练日志观察训练稳定性。实验结果表明：没有位置编码时，模型即使 loss 下降，也几乎不能生成完整正确序列；正弦位置编码在收敛速度和最终 sequence accuracy 上表现最好；去掉残差连接会使模型难以学习，而去掉 LayerNorm 会导致梯度范数出现数量级爆炸。整体结果说明，Transformer 的有效性并不只来自 attention 公式本身，而是来自注意力、位置编码、前馈网络、残差路径与归一化机制的协同作用。

关键词：Transformer；Self-Attention；Positional Encoding；Residual Connection；LayerNorm；Ablation Study；Sequence Accuracy

1 引言

序列转导任务要求模型将一个输入序列映射为另一个输出序列，典型应用包括机器翻译、语音识别和文本摘要等。传统 encoder-decoder 模型通常依赖 RNN、LSTM 或 CNN

建模序列依赖。RNN 具有天然的顺序归纳偏置，但难以在时间维度并行；CNN 可以并行计算，但要捕捉长距离依赖通常需要堆叠较多层。

Transformer 的核心思想是去掉循环和卷积结构，主要依靠 attention mechanism 建模序列内部和序列之间的依赖关系。原论文在机器翻译任务上取得了较好结果，但完整复现 WMT 2014 英德、英法翻译实验需要较大的语料和算力。因此，本文不以复现原论文 BLEU 分数为目标，而是围绕课程作业要求，重点回答 Transformer 中若干关键模块为什么必要。

本文主要讨论以下问题：

- (1) 如果不加入位置编码，或者只加入简单绝对位置编码，模型是否仍能完成顺序敏感任务？
- (2) 正弦位置编码和可学习位置编码在收敛速度、完整序列准确率和梯度稳定性上有何差异？
- (3) 残差连接和 LayerNorm 是辅助结构，还是深层 Transformer 稳定训练的必要条件？
- (4) 只观察 token accuracy 是否足够，为什么需要 sequence accuracy、loss drop、gradient norm 等更丰富指标？

2 任务设计与复现范围

2.1 Synthetic Reverse Task

本文使用 synthetic reverse task。给定输入序列

$$\mathbf{x} = [x_1, x_2, \dots, x_n],$$

目标输出为

$$\mathbf{y} = [x_n, x_{n-1}, \dots, x_1, \text{EOS}].$$

训练时 decoder 输入为

$$[\text{BOS}, x_n, x_{n-1}, \dots, x_2].$$

该任务的优点是标签完全可控，不受语料清洗、分词和语义歧义影响。同时，它对顺序非常敏感：如果模型只知道输入中有哪些 token，却不知道 token 的位置，就无法完成严格反转。因此，它特别适合检验位置编码和 cross-attention 是否学习到了位置对齐关系。

2.2 与原论文完整复现的区别

本文复现 Transformer 的核心结构，而不复现大规模 WMT 机器翻译训练结果。这样做有两个原因：第一，课程作业通常无法承担大规模语料和多 GPU 训练成本；第二，

本文关注结构必要性而不是翻译任务分数。为了避免结论过度外推，本文只声称 reverse task 上的结构消融结果能说明 Transformer 在顺序建模中的若干机制，而不声称它等价于真实机器翻译任务。

3 Transformer 核心结构

3.1 Scaled Dot-Product Attention

给定 query、key 和 value 矩阵 Q, K, V ，scaled dot-product attention 定义为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$

其中， QK^T 用于计算当前位置与其他位置的匹配程度， $\sqrt{d_k}$ 用于避免点积过大导致 softmax 饱和， V 则提供被加权读取的内容。

3.2 Multi-Head Attention

多头注意力将 Q, K, V 投影到多个子空间中并行计算：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O,$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V).$$

在 reverse task 中，不同 attention head 可能学习不同的对齐规律。例如，有些 head 可能更关注反对角线位置，有些 head 则负责处理 EOS 或局部 token 复制。

3.3 位置编码

由于 Transformer 没有循环或卷积结构，如果不加入额外位置信息，self-attention 本身对输入 token 的排列顺序并不敏感。原论文使用正弦/余弦位置编码：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right),$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right).$$

本文比较四种位置设置：No PE、Simple PE、Learned PE 和 Sinusoidal PE。

3.4 残差连接与 LayerNorm

标准 Transformer 子层使用 Add & Norm：

$$\text{LayerNorm}(x + \text{Sublayer}(x)).$$

残差路径使低层信息和梯度可以更直接地传播；LayerNorm 则稳定不同层之间的激活尺度。本文将其拆开做消融，避免只笼统地说 Add & Norm 有用。

4 实验设计

4.1 数据与训练设置

本实验采用随机生成的整数序列，训练长度范围为 5–20，OOD 测试长度范围为 21–40。模型采用轻量 Transformer: $d_{model} = 128$ ，head 数为 4，encoder/decoder 层数为 4，前馈层维度为 512，dropout 为 0.1，优化器为 Adam。训练过程中使用 teacher forcing，并在验证集上同时计算 teacher forcing 和 greedy decoding 下的指标。

4.2 实验组设置

表 1: 位置编码消融实验设置

实验组	设置	目的
No PE	不加入位置编码	验证没有顺序信息时能否反转序列
Simple PE	简单绝对位置编码	检验粗粒度绝对位置是否足够
Learned PE	可学习位置编码	检验可训练位置向量的表达能力
Sinusoidal PE	正弦/余弦位置编码	复现原论文设置，作为主 baseline

表 2: 残差连接与归一化消融实验设置

实验组	子层形式	目的
Standard Add & Norm	$\text{LN}(x + \text{Sublayer}(x))$	标准结构
No Residual	$\text{LN}(\text{Sublayer}(x))$	去掉残差路径
No LayerNorm	$x + \text{Sublayer}(x)$	去掉归一化
No Residual & No LayerNorm	$\text{Sublayer}(x)$	同时去掉二者

5 评价指标

为了避免只用一个 accuracy 得出片面结论，本文使用如下指标：

表 3: 本文使用的评价指标

指标	含义
Train Loss / Valid Loss	交叉熵损失，观察模型是否收敛
Teacher Token Accuracy	teacher forcing 条件下逐 token 准确率，反映局部分类能力

Greedy Token Accuracy	自回归生成条件下逐 token 准确率，更接近真实推理
Sequence Accuracy	整条序列完全正确的比例，是 reverse task 最严格指标
Best Sequence Accuracy	训练过程中出现过的最佳完整序列准确率
Best Epoch	最佳完整序列准确率出现的轮次，用于衡量收敛速度
Valid Loss Drop	第 1 轮到最后 1 轮的验证损失下降幅度
Mean/Max Gradient Norm	梯度范数均值和最大值，用于观察训练稳定性

6 实验结果与分析

6.1 位置编码实验结果

表 4: 位置编码实验最终结果与扩展指标

实验组	Valid Loss	Teacher Acc	Greedy Acc	Final Seq	Best Seq	Best Epoch	Loss Drop	Mean Grad	Max Grad
No PE	1.74	34.00	15.52	0.00	0.20	8	0.88	0.95	1.43
Simple PE	0.41	86.88	56.27	27.10	27.10	12	2.21	1.67	3.01
Learned PE	0.06	98.05	86.75	76.90	76.90	12	2.51	1.65	2.33
Sinusoidal PE	0.04	98.80	92.52	85.50	86.60	11	2.60	1.56	2.83

从表中可以看到，不加位置编码时，模型的验证损失虽然从 2.62 降至 1.74，teacher token accuracy 也达到 34.00%，但 final sequence accuracy 仍为 0.00%。这说明模型学到了一部分局部 token 分布规律，却没有真正掌握完整反转关系。Simple PE 能将最终 sequence accuracy 提升到 27.10%，说明即使粗糙的绝对位置信息也有帮助，但其表达能力不足。Learned PE 的最终 sequence accuracy 为 76.90%，明显优于 Simple PE，说明可训练位置向量能够更灵活地表示不同位置。Sinusoidal PE 的最终 sequence accuracy 达到 85.50%，最佳值为 86.60%，且最佳轮次出现在第 11 轮，说明原论文位置编码不仅有效，而且收敛较快。




图 1: 不同位置编码方式下的验证损失曲线。Sinusoidal PE 下降最快, No PE 下降最慢且最终停留在较高水平。




图 2: 不同位置编码方式下的完整序列准确率曲线。No PE 几乎无法生成完整正确序列, Sinusoidal PE 最终效果最好。




图 3: 位置编码最终准确率对比。Greedy token accuracy 与 sequence accuracy 的差距说明, 只看逐 token 准确率会高估模型的序列级能力。

进一步看图中曲线, Sinusoidal PE 在第 3–5 轮就出现明显跃升, 而 Learned PE 的提升更平滑、更滞后。这一现象说明, 位置编码不仅决定模型能否学习顺序关系, 还影响收敛速度。对于 reverse task, 模型需要学习目标位置 i 与源位置 $n - i + 1$ 的对应关系, 高质量的位置表示会显著降低学习难度。

6.2 残差连接与 LayerNorm 消融结果

表 5: 残差连接与 LayerNorm 消融实验结果

实验组	Train Loss	Valid Loss	Teacher Acc	Greedy Acc	Sequence Acc	Grad Norm
Standard Add & Norm	0.10	0.04	98.80	92.52	85.50	0.78
No Residual	2.88	2.84	12.44	12.44	0.00	0.24
No LayerNorm	104.96	60.59	5.49	5.33	0.00	62596.65
No Residual & No LayerNorm	3.06	3.04	11.18	11.18	0.00	0.55

标准 Add & Norm 结构取得最优结果, 最终 sequence accuracy 为 85.50%, 梯度范数仅为 0.78。去掉残差连接后, 模型最终 sequence accuracy 为 0.00%, teacher 和 greedy token accuracy 也只有 12.44%, 说明缺少残差路径后深层网络难以保留输入信息并形成有效表示。去掉 LayerNorm 后, 结果更加极端: valid loss 高达 60.59, 梯度范数达到 62596.65, 说明训练过程出现严重数值不稳定。该结果表明, LayerNorm 不是装饰性模块, 而是控制深层 Transformer 激活尺度和梯度规模的关键机制。




图 4: 残差连接与 LayerNorm 消融的完整序列准确率对比。只有标准 Add & Norm 能稳定完成 reverse task。




图 5: 残差连接与 LayerNorm 消融的梯度范数对比。图中使用对数坐标，No LayerNorm 的梯度范数明显异常。

6.3 结合终端日志的训练稳定性观察

在最新一次终端运行日志中，标准 Add & Norm 组前 8 个 epoch 的梯度范数基本维持在 0.69–1.50；No Residual 组也没有爆炸，但 loss 下降很慢，sequence accuracy 始终接近 0；No LayerNorm 组在前两轮即出现 10^5 量级梯度范数。这说明去掉 LayerNorm 的主要问题不是简单的“学得慢”，而是训练过程本身变得不稳定。




图 6: 最新终端日志中的梯度范数变化。No LayerNorm 在前两轮已经出现梯度爆炸迹象。

7 讨论

7.1 为什么 loss 下降不等于模型真正学会了反转

No PE 的实验尤其值得注意。它的 valid loss 明显下降，teacher token accuracy 也持续提升，但 sequence accuracy 基本为 0。这说明局部 token 分类指标可能掩盖序列级失败。对于 reverse task，只有每个位置都正确，整条序列才算成功。因此，sequence accuracy 比 teacher token accuracy 更能反映模型是否真正学会了算法结构。

7.2 位置编码的核心作用

位置编码的作用不是简单提高参数量，而是向模型注入顺序坐标。Self-attention 能够计算 token 之间的内容相关性，但如果没有位置坐标，模型难以判断相同 token 出现在不同位置时应如何处理。实验中 No PE 组几乎无法获得完整正确序列，说明位置编码是 Transformer 处理有序序列任务的必要条件。

7.3 残差连接与 LayerNorm 的作用区分

残差连接和 LayerNorm 经常被一起称为 Add & Norm，但二者作用并不相同。残差连接主要提供信息和梯度的捷径，使子层学习对输入表示的增量修正；LayerNorm 主要控制激活和梯度的数值尺度。实验中 No Residual 组没有明显梯度爆炸，但几乎学不动；No LayerNorm 组则出现大规模梯度异常。这一区分比简单说“Add & Norm 有用”更准确。

8 结论

本文基于 synthetic reverse task 对 Transformer 的关键结构进行了复现与消融分析。实验结果表明：第一，位置编码是 Transformer 完成顺序敏感任务的必要模块，其中 Sinusoidal PE 在收敛速度和最终完整序列准确率上表现最好；第二，单纯观察 loss 或 teacher token accuracy 不足以判断模型是否掌握了序列映射，必须结合 greedy token accuracy 和 sequence accuracy；第三，残差连接和 LayerNorm 共同保证深层 Transformer 的可训练性，其中残差连接有助于信息与梯度传播，LayerNorm 则对数值稳定性至关重要。

与原始版本相比，本文增加了最佳轮次、loss 下降幅度、梯度范数均值/最大值等指标，并通过曲线图和柱状图展示结果，使结论更具体、更可检验。后续如果继续扩展，可进一步加入 Q/K/V 共享消融、CNN 替代 self-attention 对照实验，以及 Test-ID 与 Test-OOD 的长度外推对比。

参考文献

- [1] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017.
- [2] He, K., Zhang, X., Ren, S., & Sun, J. Deep Residual Learning for Image Recognition. CVPR, 2016.